

Penerapan Algoritma FP-Growth Untuk Menentukan Pola Penjualan Najah Mart

Application of the FP-Growth Algorithm to Determine Sales Patterns at Najah Mart

Serli^{a,1}, Rujianto Eko Saputro^{b,2}

^{a,b}Universitas Amikom Purwokerto, Jl. Letjend Pol. Soemarto No.126, Watumas, Purwanegara, Kec. Purwokerto Utara, Banyumas, Jawa Tengah, 53127, Indonesia
sese84317@gmail.com¹, rujianto@amikompurwokerto.ac.id²

ABSTRAK

Penelitian ini bertujuan untuk menerapkan algoritma FP-Growth di Najah Mart dengan fokus pada identifikasi pola penjualan yang signifikan. Data transaksi yang digunakan dikumpulkan dari sistem pencatatan penjualan Najah Mart selama periode Juli hingga Oktober 2024, mencakup 117 transaksi yang telah melalui tahapan preprocessing guna memastikan kualitas data yang optimal. Algoritma FP-Growth diterapkan untuk mengungkap pola dan asosiasi antar produk berdasarkan kebiasaan pembelian pelanggan. Hasil penelitian mengungkapkan beberapa pola pembelian yang kuat, misalnya kombinasi antara Aoka dan Sari Roti, yang menunjukkan tingkat *support* sebesar 0,95 dan *confidence* 0,8. Hal ini mengindikasikan bahwa pelanggan yang membeli Aoka cenderung juga membeli Sari Roti. Selain itu, ditemukan bahwa Mantel sering dibeli bersamaan dengan Spirtus, serta pola transaksi berdasarkan kategori produk. Temuan ini dapat dimanfaatkan untuk mengoptimalkan strategi pemasaran, penerapan *bundling* produk, serta pengelolaan stok yang lebih efisien. Keberhasilan penelitian ini terletak pada penerapan metode FP-Growth untuk analisis mendetail terhadap pola pembelian di lingkungan ritel skala kecil, yang masih jarang dilakukan dalam studi-studi sebelumnya. Dengan pendekatan ini, Najah Mart berpotensi meningkatkan efektivitas operasional dan daya saingnya di pasar ritel yang semakin kompetitif.

Kata Kunci : FP-Growth, Data Mining, Najah Mart, Knowledge Discovery Database, Retail

ABSTRACT

This study aims to apply the FP-Growth algorithm at Najah Mart with a focus on identifying significant sales patterns. The transaction data used is collected from Najah Mart's sales recording system during the period July to October 2024, covering 117 transactions that have gone through a preprocessing stage to ensure optimal data quality. The FP-Growth algorithm was applied to uncover patterns and associations between products based on customer purchasing habits. The results revealed some strong purchase patterns, such as the combination of Aoka and Sari Roti, which showed a support level of 0.95 and confidence of 0.8. This indicates that customers who buy Aoka tend to also buy Sari Roti. In addition, it was found that Coats are often purchased together with Spirtus, as well as transaction patterns based on product categories. These findings can be used to optimize marketing strategies, product bundling, and more efficient stock management. The success of this research lies in the application of the FP-Growth method for detailed analysis of purchasing patterns in a small-scale retail environment, which has rarely been done in previous studies. With this approach, Najah Mart has the potential to improve its operational effectiveness and competitiveness in an increasingly competitive retail market.

Keywords : FP-Growth, Data Mining, Najah Mart, Knowledge Discovery Databases, Retail

Disubmit:

Info Artikel :
Direview:

Diterima :

Copyright © 2025 – CSRID Journal. All rights reserved.

1. PENDAHULUAN

Dalam era persaingan bisnis ritel yang semakin ketat, pemanfaatan data transaksi telah menjadi hal yang sangat penting bagi perusahaan untuk meningkatkan efisiensi operasional dan daya saing (Rafles,

2023). Data transaksi menyimpan informasi berharga (Carudin, 2021), termasuk pola pembelian pelanggan, yang dapat dimanfaatkan untuk mendukung pengambilan keputusan strategis, seperti pengoptimalan stok, peningkatan layanan pelanggan, dan penyusunan strategi pemasaran yang lebih efektif (Valencia & Atmojo, 2024). Namun, banyak bisnis ritel berskala kecil, seperti *Najah Mart*, menghadapi tantangan dalam memanfaatkan data transaksi secara optimal.

Sebagai sebuah toko *ritel* yang melayani berbagai kebutuhan sehari-hari, *Najah Mart* pernah mencatat ratusan transaksi setiap bulannya. Namun, *Najah Mart* masih menghadapi tantangan dalam mengelola dan menganalisis data yang ada. Saat ini, data transaksi di *Najah Mart* hanya digunakan untuk pencatatan kas dan stok secara manual, tanpa pemanfaatan analisis yang mendalam untuk memahami pola belanja pelanggan. Hal ini mengakibatkan munculnya berbagai peluang bisnis yang belum dapat dimanfaatkan secara optimal, seperti strategi *bundling* produk, penyesuaian stok sesuai permintaan musiman, dan promosi yang berbasis kebiasaan pelanggan. Selain itu, sering kali terjadi penumpukan stok untuk produk tertentu yang kurang diminati, sementara produk *populer* sering kali kehabisan stok. Semua ini disebabkan oleh kurangnya wawasan yang didasarkan pada data dalam perencanaan persediaan.

Salah satu metode yang terbukti efektif dalam menganalisis pola transaksi adalah teknik data *mining*, terutama melalui algoritma FP-Growth. FP-Growth adalah metode yang mampu mengidentifikasi hubungan asosiasi antar produk tanpa perlu melakukan perhitungan iteratif berulang seperti yang dilakukan oleh algoritma Apriori (Erwin, 2019). Hal ini membuat FP-Growth lebih cepat dan efisien dalam menangani data dalam jumlah besar (Raihan, 2024). Selain itu, FP-Growth adalah salah satu algoritma yang dapat digunakan untuk mengidentifikasi himpunan data yang sering muncul (*frequent itemset*) dalam suatu kumpulan data (Munanda & Monalisa, 2021). Beberapa penelitian sebelumnya telah menunjukkan bahwa metode FP-Growth cukup efektif dalam mengidentifikasi pola belanja pelanggan. Misalnya hasil penelitian mengenai penerapan algoritma FP-Growth untuk mendukung pola pembelian sembako di Toko Uci menunjukkan bahwa algoritma ini efektif dalam mengidentifikasi pola penjualan. Dari analisis yang dilakukan, ditemukan bahwa kombinasi produk seperti Beras, Aci, dan Bawang Merah memiliki nilai kepercayaan hingga 90,9%. Selain itu, produk Masako dan Bawang Putih, serta Telur dengan Bawang Merah, juga menunjukkan pola pembelian yang signifikan. Penelitian ini menemukan bahwa ada tiga kelompok item yang paling banyak diminati konsumen, dengan nilai keyakinan tertinggi mencapai 100% antara kombinasi Telur, Aci, dan Bawang Merah. Hasil ini memberikan wawasan penting bagi strategi penjualan dan pengelolaan stok di Toko Uci, serta membantu meningkatkan kualitas produk dan memaksimalkan penjualan. Kesimpulannya, penerapan algoritma FP-Growth dapat dijadikan dasar untuk meningkatkan efisiensi operasional dan daya saing toko sembako (Indah & Ali, 2024). Selain itu penelitian yang dilakukan oleh (Tarwoto et al., 2025) dengan hasil penelitian mengenai penerapan algoritma FP-Growth untuk strategi penjualan di Toko Kelontong Cipta Lestari menunjukkan bahwa algoritma ini efektif dalam mengidentifikasi pola pembelian yang signifikan. Dengan menggunakan parameter *support* sebesar 0,95 dan *Confidence* sebesar 0,8, penelitian ini menemukan bahwa produk seperti Kchoco, sambal, dan teh 3350ml sering dibeli bersamaan dengan kopi Torabika, kecap, dan mie goreng. Pola kombinasi ini memungkinkan Toko Cipta Lestari untuk merancang promosi produk yang lebih efektif dan mengoptimalkan manajemen inventaris. Temuan ini juga menunjukkan bahwa penerapan algoritma FP-Growth dapat membantu toko dalam memahami preferensi pelanggan, meningkatkan kepuasan melalui penawaran produk yang tepat, serta memperkuat strategi pemasaran dan daya saing di pasar. Penelitian ini memberikan kontribusi penting bagi pengembangan strategi pemasaran tradisional dan analisis pola pembelian konsumen di masa mendatang.


Hingga kini, penelitian yang secara khusus mengaplikasikan metode FP-Growth pada ritel skala kecil, seperti yang dialami oleh *Najah Mart*, masih sangat terbatas. Kebanyakan penelitian sebelumnya cenderung berfokus pada ritel berskala besar atau toko-toko yang memiliki sistem pencatatan yang lebih

teratur. Hal ini menciptakan kesenjangan dalam kajian mengenai penerapan FP-Growth pada toko *ritel* kecil yang seringkali mengalami tantangan dalam pengelolaan data transaksi.

Penelitian ini bertujuan untuk menerapkan metode FP-Growth dalam mengidentifikasi pola penjualan di Najah *Mart*. Tujuannya adalah untuk memberikan wawasan berbasis data yang dapat membantu dalam pengelolaan stok, penyusunan strategi promosi, serta peningkatan layanan pelanggan. Kebaruan dari penelitian ini terletak pada penggunaan FP-Growth untuk menganalisis pola pembelian pada ritel skala kecil dengan data transaksi yang lebih terbatas, yang merupakan hal yang jarang dijumpai dalam penelitian sebelumnya. Kontribusi ilmiah dari studi ini adalah penyediaan model penerapan FP-Growth yang dapat diadaptasi oleh bisnis ritel kecil yang ingin memaksimalkan pemanfaatan data transaksinya tanpa harus bergantung pada sistem pencatatan yang rumit. Melalui pendekatan berbasis data ini, diharapkan Najah *Mart* dapat meningkatkan efektivitas operasional dan daya saingnya di pasar *ritel* yang semakin ketat.

2. METODE PENELITIAN

Dalam penelitian *Knowledge Discovery in Databases* (KDD) untuk mencari pola penjualan Najah *Mart* dengan FP-Growth, langkah-langkahnya terdiri dari beberapa tahapan penting. Langkah pertama adalah mengumpulkan data transaksi penjualan yang relevan. Langkah berikutnya adalah melakukan tahap *preprocessing* untuk membersihkan dan memformat data sehingga siap untuk analisis. Hal ini melibatkan menghilangkan data yang tidak *valid* dan mengatur format yang konsisten. Setelah data siap, algoritma FP-Growth digunakan untuk mencari pola dan asosiasi dalam data penjualan. Hasil dari penggunaan algoritma ini akan menunjukkan pola pembelian yang bisa digunakan untuk membuat keputusan strategis dalam mengelola stok dan pemasaran produk di Najah *Mart*. Gambar 1 menampilkan langkah-langkah dalam proses penelitian dengan cara visual.



Gambar 1. Proses Data Mining

A. Selection

Pemilihan data atau *selection* adalah langkah awal dalam proses KDD yang bertujuan untuk memilih himpunan data yang relevan dari kumpulan data yang lebih besar (Erwansyah et al., 2021). Pada tahap ini, pemilihan himpunan data dilakukan, dimana fokusnya adalah pada subset variabel atau sampel yang akan digunakan untuk penemuan pola. Pemilihan ini memastikan bahwa hanya data yang relevan yang dapat diproses lebih lanjut (Harahap & Nastuti, 2019). Dalam penelitian ini, *selection* berfungsi untuk memastikan data transaksi Najah *Mart* yang digunakan relevan, lengkap, dan sesuai dengan tujuan analisis. Dengan proses *selection* yang terencana, algoritma FP-Growth bisa dengan baik menemukan pola penjualan yang penting, seperti yang diharapkan dalam penelitian ini, untuk membantu pengelolaan persediaan, merancang strategi pemasaran, dan meningkatkan pengalaman pelanggan di Najah *Mart*. Data yang digunakan dalam penelitian ini berupa transaksi penjualan harian di Najah *Mart*, yang dikumpulkan melalui metode observasi langsung dari sistem pencatatan kasir. Pengumpulan data berlangsung selama empat bulan, yaitu dari Juli hingga Oktober 2024, dengan total 117 transaksi. Informasi ini diperoleh dari catatan penjualan yang mencakup beragam produk yang dipasarkan selama

periode tersebut. Atribut yang digunakan dalam penelitian ini terdiri dari berbagai jenis produk yang tercatat dalam data transaksi, mencakup kategori makanan, minuman, kebutuhan rumah tangga, serta perlengkapan lainnya. Atribut tersebut antara lain Tanggal, Kas, Produk, Aoka, Ubi, Peniti, Buah Pir, Beras, Spirtus, Coca Cola, Rokok, Wafelo, Hydro Coco, Teh Tarik, Plastik, Mantel, Purnama Toys, Materai, Solasi, Madu Rasa, Listrik, Tinta, Yakult, Ciki, Gas, Frisian Flag, Sari Roti, Cimory, Telur, Madu Rasa Jeruk, Jajan, Jajan Pasar, Plastik Parcel, Ladaku, Double Tape, Margarin, Kecap, Oreo, Wipol, Sunlight, Gula, Sari Gandum, Vit, Lampu, Ades, Kuncir Rambut, Tisu Paseo, Aice, Parfum, ATK, Permen Kaki, Indomaret, Kerupuk, dan Minyak. Atribut-atribut ini digunakan dalam analisis pola penjualan dengan algoritma FP-Growth untuk mengidentifikasi hubungan antar produk dan mendukung pengambilan keputusan strategis.

B. Preprocessing

Preprocessing adalah langkah krusial dalam analisis data mining. Tujuan dari proses ini adalah untuk membersihkan, mengubah format, dan menyiapkan data sehingga dapat dianalisis dengan lebih mudah dan akurat (Agung et al., 2023). Secara umum, data yang diperoleh, baik dari basis data perusahaan maupun hasil eksperimen, sering kali memiliki kekurangan, seperti adanya data yang hilang, data yang tidak valid, atau bahkan kesalahan pengetikan. Selain itu, terdapat pula atribut data yang tidak relevan; keberadaan atribut tersebut sebaiknya dihapus, karena dapat mengurangi kualitas dan akurasi hasil data mining di kemudian hari (Widayati, 2018).

C. Transformation

Transformasi dalam Penemuan Pengetahuan dalam Basis Data (KDD) mengacu pada tahapan penting dalam memproses data, di mana data yang telah dipilih diubah menjadi format yang tepat untuk analisis lebih lanjut. Proses ini terdiri dari beberapa langkah penting: pemilihan data yang relevan, *preprocessing* untuk membersihkan dan memformat data agar siap untuk analisis, serta transformasi seperti normalisasi, kategorisasi, *encoding*, pengurangan dimensi, dan penyusunan transaksi. Dengan melakukan transformasi yang sesuai, data akan menjadi lebih terstruktur dan siap untuk digunakan dalam analisis algoritma, sehingga kemampuan untuk menemukan pola tersembunyi dalam dataset juga akan meningkat (Alghifari & Juardi, 2021).

D. Data Mining

Memilih algoritma yang tepat untuk proses data mining merupakan langkah krusial dalam penelitian ini. Algoritma yang dipilih dapat bervariasi sesuai dengan tujuan dan keseluruhan proses *Knowledge Discovery in Databases* (KDD). Beberapa algoritma yang umum digunakan mencakup klasifikasi, FP-Growth, *clustering*, dan analisis asosiasi (Sari & Sari siregar, 2021). Dalam penelitian ini, algoritma FP-Growth diterapkan menggunakan aplikasi *RapidMiner*, dengan tujuan utama untuk mengidentifikasi itemset yang saling terkait dan menghasilkan nilai yang optimal. Proses ini dilakukan melalui penggunaan operator FP-Growth dan *Create Association Rule*. Analisis asosiasi dalam data *mining* terdiri dari dua tahap utama. Tahap pertama berfokus pada pengenalan itemset yang sering muncul untuk menetapkan nilai *support minimum*, yang memberikan gambaran seberapa sering itemset tersebut terlihat dalam data (Muhammad Alvin et al., 2022). Pada tahap kedua, perhatian diberikan pada penghasilan aturan asosiasi sesuai dengan apa yang diharapkan dari itemset tersebut (Nurasiah, 2021). Hal ini bertujuan untuk memastikan bahwa aturan yang dihasilkan memenuhi kriteria *minimum support* dan *confidence*, sehingga dapat mengidentifikasi pola pembelian yang signifikan dalam data penjualan. Dalam penelitian ini, nilai *minimum support* ditetapkan sebesar 0,95 (95%), sementara nilai *minimum confidence* sebesar 0,8 (80%). Pemilihan nilai ini didasarkan pada kombinasi studi sebelumnya mengenai penerapan algoritma FP-Growth di sektor ritel dan eksperimen awal yang dilakukan terhadap dataset yang digunakan. Penelitian seperti yang dilakukan oleh (Tarwoto et al., 2025) menunjukkan bahwa rentang nilai *support* dan *confidence* tersebut efektif dalam mengidentifikasi pola pembelian yang bermakna, tanpa menghasilkan aturan yang terlalu banyak atau sedikit. Dengan penerapan nilai parameter ini, penelitian ini diharapkan dapat menemukan aturan asosiasi yang cukup kuat, yang

selanjutnya dapat memberikan wawasan berharga bagi pengelolaan stok dan strategi pemasaran di Najah Mart.

E. Evaluasi

Evaluasi dilakukan untuk menilai pola-pola yang teridentifikasi selama proses pengolahan data, dengan tujuan untuk memastikan kesesuaian pola-pola tersebut dengan hipotesis awal atau fakta yang sudah ada (Sumilat et al., 2019). Pada tahap ini, algoritma FP-Growth diterapkan secara eksklusif untuk mengevaluasi pola asosiasi dalam data penjualan Najah Mart, tanpa membandingkannya dengan algoritma lainnya. Proses evaluasi ini melibatkan pengamatan terhadap beberapa metrik, seperti *support*, *confidence*, *lift*, *Premises*, *Conclusion*, *LaPlace*, *p-s* dan *conviction*.

Metrik *support* mengukur frekuensi kemunculan itemset, sedangkan *confidence* menilai kekuatan hubungan antar item. *Lift* menggambarkan seberapa kuat hubungan tersebut jika dibandingkan dengan kemungkinan kemunculan secara acak, sedangkan *conviction* menilai keandalan aturan yang ditemukan. Selain itu, evaluasi ini juga mencakup metrik tambahan seperti *Premises* dan *Conclusion*, yang mengidentifikasi bagian dari aturan asosiasi, *LaPlace* yang mengukur probabilitas kejadian itemset, Gain yang menunjukkan keuntungan informasi dari aturan tersebut, serta *p-s* yang menggambarkan sejauh mana aturan asosiasi dapat mengurangi ketidakpastian dalam memprediksi hasil transaksi.

Hasil dari evaluasi ini menghasilkan informasi berharga bagi pengambil keputusan dalam merancang strategi pemasaran dan mengelola stok. Dengan demikian, hal ini berkontribusi pada peningkatan penjualan dan kemampuan dalam memenuhi kebutuhan konsumen.

3. HASIL DAN PEMBAHASAN

A. Selection

Studi ini menggunakan data penjualan yang dikumpulkan melalui metode observasi di Najah Mart. Data yang dianalisis dalam penelitian ini mencakup transaksi penjualan harian yang telah tercatat secara teratur selama empat bulan, yaitu Juli, Agustus, September, dan Oktober 2024. Informasi yang telah dikumpulkan mencakup rincian lengkap masing-masing transaksi, seperti tanggal, jenis produk yang terjual. Data ini akan menjadi pondasi utama dalam analisis yang bertujuan untuk menemukan pola penjualan, tren musiman, serta hubungan antar produk yang sering dibeli bersamaan. Dengan data yang kaya dan terorganisir ini, peneliti diharapkan bisa memberikan wawasan berharga yang mendukung pengambilan keputusan strategis, seperti pengelolaan stok, penyusunan promosi, dan perencanaan penjualan dimasa depan.

Tabel 1. Transaksi Penjualan Najah Mart

| LAPORAN KEUANGAN NAJAH MART | | | | | | |
|-----------------------------|------------|-----------|----------------|---------------|-----------------|-------|
| Tanggal | Transaksi | | Pemasukan | | Pengeluaran | SALDO |
| Oktober 2024 | | | | | | |
| | KAS | | Rp 654.399,00 | | Rp 654.399,00 | |
| 10/01/2024 | Hasil Jual | | Rp1.135.900,00 | | Rp 1.617.799,00 | |
| | | Aoka | | Rp 172.500,00 | Rp 1.617.799,00 | |
| | | Ubi | | | | |
| | | Peniti | | | | |
| | | Buah Pir | | | | |
| | | Beras | | | | |
| | | Spirtus | | | | |
| | | Coca Cola | | | | |

| | | | | | |
|------------|------------|--------------|----------------|---------------|-----------------|
| | | Rokok | | | |
| | | Wafelo | | | |
| | | Hydro Coco | | | |
| | | The Tarik | | | |
| | | Plastik | | | |
| | | Mantel | | | |
| | | Purnama Toys | | | |
| | | Materai | | | |
| | | Spirtus | | | |
| | | Solasi | | | |
| | | Madu Rasa | | | |
| | | Listrik | | | |
| | | Tinta | | | |
| 2/10//2024 | Hasil Jual | | Rp1.281.600,00 | | Rp 2.669.399,00 |
| | | Aoka | | Rp 230.000,00 | Rp 2.569.059,00 |
| | | Peniti | | Rp 100.340,00 | Rp 2.539.659,00 |
| | | Buah Pir | | Rp 29.400,00 | Rp 2.459.659,00 |
| | | Beras | | Rp 80.000,00 | Rp 2.459.659,00 |
| | | Spirtus | | | |
| | | Coca Cola | | | |
| | | Rokok | | | |
| | | Wafelo | | | |
| | | Hydro Coco | | | |
| | | The Tarik | | | |
| | | Plastik | | | |
| | | Mantel | | | |
| | | Solasi | | | |
| | | Listrik | | | |
| | | Tinta | | | |
| | | Gas | | | |

| | | | | | |
|------------|------------|---------------|--|---------------|-----------------|
| | | Frisian Flag | | | |
| | | Sari Roti | | | |
| | | Cimory | | | |
| | | Telur | | | |
| | | Jajan | | | |
| | | Jajan Pasar | | | |
| | | Ladaku | | | |
| | | Double Tape | | | |
| | | Kecap | | | |
| | | Oreo | | | |
| | | Sunlight | | | |
| | | Gula | | | |
| | | Sari Gandum | | | |
| | | Lampu | | | |
| | | Kuncir Rambut | | | |
| | | Tisu Paseo | | | |
| | | Aice | | | |
| | | Parfume | | | |
| | | Permen Kaki | | | |
| | | Indomrco | | | |
| | | Kerupuk | | | |
| | | Minyak | | | |
| | | | | | |
| 26/10/2024 | hasil jual | | | | Rp 6.816.917,00 |
| | | cimory | | Rp 243.000,00 | Rp 6.738.917,00 |

| | | | | | |
|--|--|------------|--|------------------|--------------------|
| | | roti sisir | | Rp 78.000,00 | Rp 6.078.917,00 |
| | | Aoka | | Rp 660.000,00 | Rp 5.886.317,00 |
| | | wafelo | | Rp 192.600,00 | Rp 5.881.317,00 |
| | | Hydrococo | | Rp 5.000,00 | Rp 5.861.317,00 |
| | | kerupuk | | Rp 20.000,00 | Rp 5.848.717,00 |
| | | sari roti | | Rp 12.600,00 | Rp 5.781.117,00 |
| | | cimory | | Rp 67.600,00 | Rp 5.767.117,00 |
| | | roti sisir | | Rp 14.000,00 | Rp 5.665.817,00 |
| | | Aoka | | Rp 101.300,00 | Rp 5.648.817,00 |

Data penjualan harian yang ditampilkan dalam Tabel 1 belum terstruktur dengan optimal. Untuk mempermudah penerapan teknik data mining dengan menggunakan aplikasi *RapidMiner*, penulis akan melakukan langkah-langkah restrukturisasi format data penjualan dari Juli hingga Oktober 2021 dengan bantuan *Microsoft Excel*.

Tabel 2. Transformasi Ke Dalam Bentuk Tabel

| Tanggal | kas | produk | Aoka | Ubi | Peniti | Buah Pir | Beras | Spirtus | Coca Cola | Rokok | Wafelo | Hydro Coco |
|------------|------------|----------|------|-----|--------|----------|-------|---------|-----------|-------|--------|------------|
| 01/07/2024 | Hasil Jual | Baris 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |
| 02/07/2024 | Hasil Jual | Baris 2 | 1 | 0 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |
| 03/07/2024 | Hasil Jual | Baris 3 | 1 | 0 | 1 | 0 | 1 | 0 | 1 | 0 | 0 | 0 |
| 04/07/2024 | Hasil Jual | Baris 4 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 1 |
| 05/07/2024 | Hasil Jual | Baris 5 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 06/07/2024 | Hasil Jual | Baris 6 | 1 | 1 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 |
| 07/07/2024 | Hasil Jual | Baris 7 | 1 | 1 | 0 | 0 | 1 | 0 | 1 | 1 | 0 | 1 |
| 08/07/2024 | Hasil Jual | Baris 8 | 1 | 1 | 1 | 0 | 1 | 1 | 1 | 0 | 1 | 1 |
| 09/07/2024 | Hasil Jual | Baris 9 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 0 | 1 |
| 10/07/2024 | Hasil Jual | baris 10 | 1 | 1 | 0 | 0 | 1 | 1 | 1 | 0 | 0 | 0 |
| 11/07/2024 | Hasil Jual | baris 11 | 1 | 1 | 1 | 0 | 1 | 1 | 1 | 0 | 1 | 1 |
| 12/07/2024 | Hasil Jual | baris 12 | 1 | 1 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 0 |
| 13/07/2024 | Hasil Jual | baris 13 | 1 | 0 | 0 | 1 | 0 | 1 | 0 | 0 | 0 | 0 |
| 14/07/2024 | Hasil Jual | baris 14 | 1 | 1 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 |

| | | | | | | | | | | | | |
|------------|---------------|--------------|---|---|---|---|---|---|---|---|---|---|
| 15/07/2024 | Hasil Jual | baris 15 | 1 | 0 | 1 | 1 | 1 | 0 | 1 | 1 | 1 | 0 |
| 16/07/2024 | Hasil Jual | baris 16 | 1 | 1 | 0 | 1 | 1 | 1 | 0 | 1 | 1 | 1 |
| 17/07/2024 | Hasil Jual | baris 17 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 |
| 18/07/2024 | Hasil Jual | baris 18 | 0 | 0 | 1 | 0 | 0 | 0 | 1 | 0 | 0 | 0 |
| 19/07/2024 | Hasil Jual | baris 19 | 0 | 0 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 0 |
| 20/07/2024 | Hasil Jual | baris 20 | 1 | 1 | 0 | 0 | 1 | 1 | 0 | 0 | 1 | 1 |
| | | | | | | | | | | | | |
| 25/10/2024 | Hasil Jual | baris 120 | 1 | 1 | 1 | 0 | 1 | 1 | 0 | 0 | 0 | 0 |

Setelah data dirapikan dalam bentuk *tabular* seperti yang tertera pada Tabel 2 beserta nilai *binomial* dimasukkan, Tahap berikutnya adalah membuat dataset ke dalam aplikasi *RapidMiner* untuk melanjutkan analisis. Sesudah data dirapikan ke dalam format tabur seperti yang ditunjukkan pada tabel 3 dan ditambahkan nilai *binomial*, langkah berikutnya adalah membuka data *set* dengan menggunakan aplikasi *RapidMiner* untuk menaljutkan analisis, setelah menginstal dan membuka *RapidMiner*, tahap-tahap berikutnya pengelolaan data dapat dimulai dengan tambahkan operator “*Read Excel*” dibagian *operators* (kanan bawah) cari operator *Read Excel* dengan mengetik di kolom pencarian kemudian *Drag and drop operator* dalam area *process*. Setelah menambahkan operator *Read Excel*, klik pada operator tersebut untuk membuka di panel sebelah kanan. Dibagian *Parameters*, klik opsi *Import Configuration Wizard*, lalu pilih file yang akan digunakan dengan cara membuka lokasi file pada komputer dan pilih file yang diinginkan. Setelah data berhasil di *import*, *RapidMiner* secara otomatis akan menyesuaikan tipe data, dengan representasi angka 1 dan 0. Dimana 1 untuk barang yang berhasil dijual sedangkan 0 untuk produk yang tidak terjual. Terakhir, klik tombol biru (*Star to Execution*), dan hasilnya akan ditampilkan seperti yang terlihat pada Gambar 2. Langkah ni memastikan bahwa informasi penjualan telah berhasil diproses dan siap digunakan untuk analisis lanjutan di *RapidMiner*.

| Open in | | Turbo Prep | Auto Model | Interactive Analysis | Filter (117 / 117 examples): all | | | | | | | |
|---------|--------------|------------|------------|----------------------|----------------------------------|--------|----------|-------|----------|--|--|--|
| Row No. | Tanggal | kas | produk | Aoka | Ubi | Peniti | Buah Pir | Beras | Spiritus | | | |
| 1 | Jul 1, 2024 | Hasil Jual | Baris 1 | 1 | 1 | 1 | 1 | 1 | 1 | | | |
| 2 | Jul 2, 2024 | Hasil Jual | Baris 2 | 1 | 0 | 1 | 1 | 1 | 1 | | | |
| 3 | Jul 3, 2024 | Hasil Jual | Baris 3 | 1 | 0 | 1 | 0 | 1 | 0 | | | |
| 4 | Jul 4, 2024 | Hasil Jual | Baris 4 | 1 | 0 | 0 | 0 | 0 | 0 | | | |
| 5 | Jul 5, 2024 | Hasil Jual | Baris 5 | 1 | 0 | 0 | 0 | 0 | 0 | | | |
| 6 | Jul 6, 2024 | Hasil Jual | Baris 6 | 1 | 1 | 1 | 0 | 1 | 1 | | | |
| 7 | Jul 7, 2024 | Hasil Jual | Baris 7 | 1 | 1 | 0 | 0 | 1 | 0 | | | |
| 8 | Jul 8, 2024 | Hasil Jual | Baris 8 | 1 | 1 | 1 | 0 | 1 | 1 | | | |
| 9 | Jul 9, 2024 | Hasil Jual | Baris 9 | 1 | 1 | 1 | 1 | 1 | 1 | | | |
| 10 | Jul 10, 2024 | Hasil Jual | baris 10 | 1 | 1 | 0 | 0 | 1 | 1 | | | |
| 11 | Jul 11, 2024 | Hasil Jual | baris 11 | 1 | 1 | 1 | 0 | 1 | 1 | | | |
| 12 | Jul 12, 2024 | Hasil Jual | baris 12 | 1 | 1 | 0 | 1 | 0 | 0 | | | |
| 13 | Jul 13, 2024 | Hasil Jual | baris 13 | 1 | 0 | 0 | 1 | 0 | 1 | | | |
| 14 | Jul 14, 2024 | Hasil Jual | baris 14 | 1 | 1 | 0 | 0 | 0 | 1 | | | |
| 15 | Jul 15, 2024 | Hasil Jual | baris 15 | 1 | 0 | 1 | 1 | 1 | 0 | | | |
| 16 | Jul 16, 2024 | Hasil Jual | baris 16 | 1 | 1 | 0 | 1 | 1 | 1 | | | |

Gambar 2. Hasil Tampilan *Star to Execution*

Dataset di import menggunakan operator *Read Excel* pada aplikasi *Rapidminer*, menghasilkan informasi statistik dengan rincian sebagai berikut:

Tabel 3. Statistik dataset

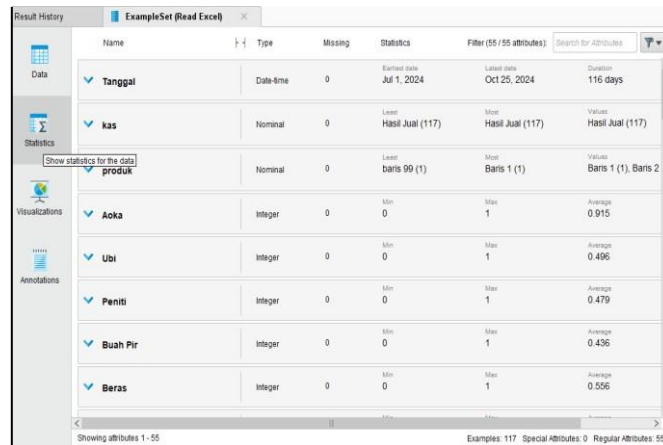
| No | Uraian | Keterangan |
|----|-----------------|------------|
| 1 | Baris Data | 117 |
| 2 | Atribut Spesial | 0 |
| 3 | Atribut Biasa | 55 |

B. Preprocessing

Setelah data dikumpulkan dan ditampilkan, langkah selanjutnya adalah memulai proses *preprocessing*. Tujuan dari tahap ini adalah untuk memastikan bahwa data yang akan digunakan dalam analisis bersih dan siap untuk diproses lebih lanjut. Langkah pertama dalam *preprocessing* adalah memeriksa keberadaan data yang hilang atau kosong. Hal ini dapat dilakukan melalui opsi Statistik pada bagian *ExampleSet* di *RapidMiner*, yang akan memberikan ringkasan statistik beserta informasi mengenai nilai yang hilang.

Apabila ditemukan data yang tidak lengkap, penulis dapat memilih untuk menghapus atau mengganti nilai yang hilang dengan teknik imputasi. Proses *preprocessing* juga mencakup penghapusan data *duplikat*, sehingga tidak ada data yang berulang yang dapat mempengaruhi hasil analisis. Selain itu, penting untuk menangani outlier, yaitu data dengan nilai ekstrem yang dapat mengganggu hasil analisis. Teknik seperti *z-score* atau *Interquartile Range (IQR)* dapat digunakan untuk mengidentifikasi dan mengatasi outlier ini.

Terakhir, data yang tidak relevan untuk analisis, seperti kolom atau atribut yang tidak mendukung tujuan penelitian, perlu dihapus. Hal ini bertujuan untuk memastikan bahwa dataset menjadi lebih fokus dan efisien. Dengan mengikuti tahapan *preprocessing* yang tepat, data yang digunakan dalam penelitian ini akan menjadi lebih bersih, terpercaya, dan siap untuk dianalisis lebih lanjut.




| Name | Type | Missing | Statistics | Filter (55 / 55 attributes) | Search by Attributes |
|------------|-----------|---------|---|-----------------------------|----------------------|
| ✓ Tanggal | Date-time | 0 | Earliest date: Jul 1, 2024 Latest date: Oct 25, 2024 Duration: 116 days | | |
| ✓ kas | Nominal | 0 | Least: Hasil Jual (117) Most: Hasil Jual (117) Value: Hasil Jual (117) | | |
| ✓ produk | Nominal | 0 | Least: Bars 99 (1) Most: Bars 1 (1) Value: Bars 1 (1), Bars 2 | | |
| ✓ Aoka | Integer | 0 | Min: 0 Max: 1 Average: 0.915 | | |
| ✓ Ubi | Integer | 0 | Min: 0 Max: 1 Average: 0.495 | | |
| ✓ Peniti | Integer | 0 | Min: 0 Max: 1 Average: 0.479 | | |
| ✓ Buah Pir | Integer | 0 | Min: 0 Max: 1 Average: 0.436 | | |
| ✓ Beras | Integer | 0 | Min: 0 Max: 1 Average: 0.555 | | |

Showing attributes 1 - 55
Examples: 117 Special Attributes: 0 Regular Attributes: 55

Gambar 3. Hasil Statistik *Read Excel*

Seperti yang terlihat pada Gambar 3, dataset penjualan Najah *Mart* tidak mengandung nilai yang hilang atau data yang tidak lengkap, yang ditandai dengan "*missing 0*". Ini menunjukkan bahwa data tersebut dalam keadaan utuh dan tidak memerlukan perbaikan lebih lanjut. Dengan demikian, tahap *preprocessing* untuk menangani nilai yang hilang atau data yang tidak lengkap telah selesai, dan kita dapat melanjutkan ke tahap berikutnya tanpa kendala. Hal ini memastikan bahwa data yang digunakan sudah siap dan dapat memberikan hasil analisis yang lebih akurat dan terpercaya.

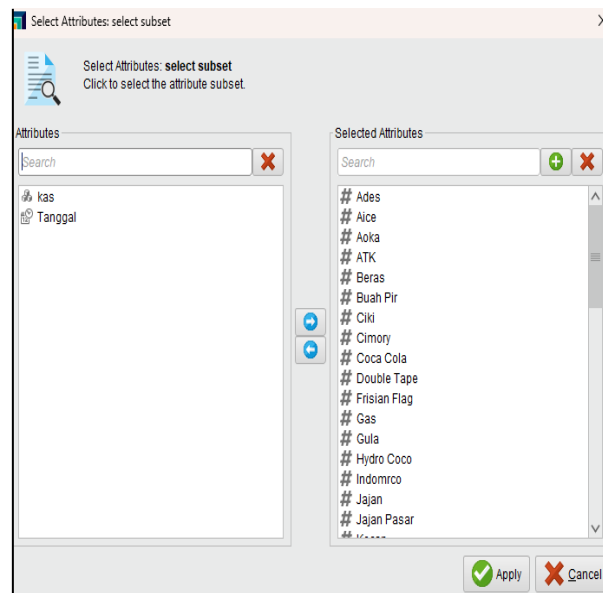
C. Transformation



Gambar 4. Operator *Select Attribute*


Sebelum mengubah tipe data pada *invoice*, langkah awal yang perlu dilakukan adalah menambahkan operator *select atribut*, seperti yang ditunjukkan pada Gambar 4. Berikutnya atur setelah parameter

subset dan dipindahkan data yang relevan ke atribut yang telah dipilih. Setelah langkah-langkah tersebut dilakukan, hasil perubahan dari proses seleksi data dapat dilihat pada Gambar 5.

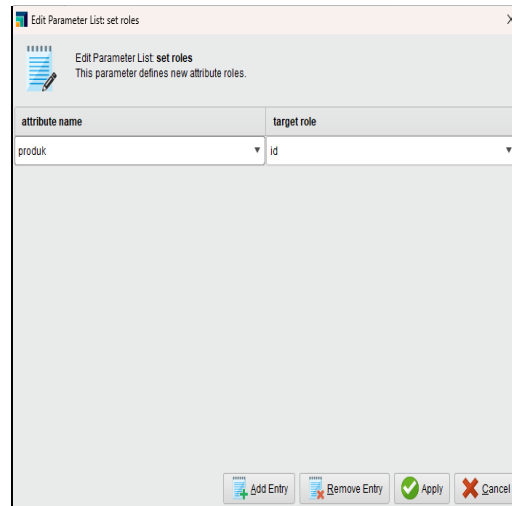


Gambar 5. *Select Attribute*

Langkah selanjutnya adalah menggunakan parameter *set role* untuk melakukan tranformasi dan mengubah tipe data pada atribut *invoice* menjadi *ID*. Pada bagian parameter atribut nama, pilih data yang akan diubah, kemudian *klik atribut invoice*, seperti yang ditunjukkan pada Gambar 6. Pada bagian ini, produk dipilih sebagai *ID* karena data dalam atribut tersebut adalah angka yang unik. Ini menjamin bahwa setiap nilai dalam atribut produk bisa berfungsi sebagai pengenalan yang tidak diulang, sehingga ideal untuk dijadikan *identifier* dalam analisis data. Setelah menemukan atribut yang akan diubah, pilih target role atau jenis data yang diinginkan, lalu *klik ID* yang ditampilkan pada Gambar 7. Tampilan *example set* dari hasil pengambilan data sebelum perubahan dapat dilihat pada Gambar 3, sementara hasil transformasi setelah penggunaan parameter *set role* terlihat pada Gambar 8. Proses ini sangat penting untuk memastikan jenis data sesuai dengan kebutuhan analisis yang akan digunakan.



Gambar 6 Pengaturan *Set Role*




Gambar 7. Attribute name dalam Set Role

| Row No. | produk | Aduka | Udu | Penuki | Buah Pir | Berran | Sphitex | Coca Cola | Biskuit |
|---------|-----------|-------|-----|--------|----------|--------|---------|-----------|---------|
| 1 | Barito 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |
| 2 | Barito 2 | 1 | 0 | 1 | 1 | 1 | 1 | 1 | 1 |
| 3 | Barito 3 | 1 | 0 | 1 | 0 | 1 | 0 | 1 | 0 |
| 4 | Barito 4 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 5 | Barito 5 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 6 | Barito 6 | 1 | 1 | 1 | 0 | 1 | 1 | 0 | 0 |
| 7 | Barito 7 | 1 | 1 | 0 | 0 | 1 | 0 | 1 | 1 |
| 8 | Barito 8 | 1 | 1 | 1 | 0 | 1 | 1 | 1 | 0 |
| 9 | Barito 9 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |
| 10 | Barito 10 | 1 | 1 | 0 | 0 | 1 | 1 | 1 | 0 |
| 11 | Barito 11 | 1 | 1 | 1 | 0 | 1 | 1 | 1 | 0 |
| 12 | Barito 12 | 1 | 1 | 0 | 1 | 0 | 0 | 1 | 0 |
| 13 | Barito 13 | 1 | 0 | 0 | 1 | 0 | 1 | 0 | 0 |
| 14 | Barito 14 | 1 | 1 | 0 | 0 | 0 | 1 | 0 | 0 |
| 15 | Barito 15 | 1 | 0 | 1 | 1 | 1 | 0 | 1 | 1 |
| 16 | Barito 16 | 1 | 1 | 0 | 1 | 1 | 1 | 0 | 1 |

Gambar 8. Hasil Perubahan Tipe data

Langkah berikutnya adalah melakukan transformasi untuk mengubah jenis data dalam dataset dari nilai *numerik* menjadi *binominal*. Perubahan ini dilakukan karena data penjualan yang dianalisis hanya terdiri dari dua nilai, yaitu nilai 1 dan 0, yang secara konsisten digunakan. Oleh karena itu, data diubah menjadi *tipe binominal*. Setelah proses transformasi data selesai, seperti yang terlihat pada gambar 8, hasil yang didapatkan akan menunjukkan nilai *true* dan *false*. Nilai *true* menunjukkan 1, sedangkan nilai *false* menunjukkan 0, seperti yang dapat dilihat pada gambar 9. Tujuan dari transformasi ini adalah untuk mempermudah analisis data dan membuat formatnya lebih cocok dengan ciri-ciri data penjualan yang hanya memiliki dua kemungkinan nilai.



Gambar 9. Operator Numerical to Binominal

| Row No. | produk | Asoka | Ubi | Peniti | Buah Pir | Beras | Spiritus | Coca Cola | Rokok |
|---------|----------|-------|-------|--------|----------|-------|----------|-----------|-------|
| 1 | Baris 1 | true | true | true | true | true | true | true | true |
| 2 | Baris 2 | true | false | true | true | true | true | true | true |
| 3 | Baris 3 | true | false | true | false | true | false | true | false |
| 4 | Baris 4 | true | false | false | false | false | false | false | false |
| 5 | Baris 5 | true | false | false | false | false | false | false | false |
| 6 | Baris 6 | true | true | true | false | true | true | false | false |
| 7 | Baris 7 | true | true | false | false | true | false | true | true |
| 8 | Baris 8 | true | true | true | false | true | true | true | true |
| 9 | Baris 9 | true | true | true | true | true | true | true | true |
| 10 | Baris 10 | true | true | false | false | true | true | true | true |
| 11 | Baris 11 | true | true | true | false | true | true | true | false |
| 12 | Baris 12 | true | true | false | true | false | false | true | false |
| 13 | Baris 13 | true | false | false | true | false | true | false | false |
| 14 | Baris 14 | true | true | false | false | true | true | false | false |
| 15 | Baris 15 | true | false | true | true | true | false | true | true |
| 16 | Baris 16 | true | true | false | true | true | true | false | true |

Gambar 10. Hasil Transformasi Data to Binominal


Tabel 4. Statistik data setelah Data Transformation

| No | Uraian | Keterangan |
|----|-----------------|------------|
| 1 | Baris Data | 117 |
| 2 | Atribut Spesial | 1 |
| 3 | Atribut Biasa | 52 |

Pada tabel 4, memberikan rincian atau gambaran tentang struktur dataset setelah dilakukan transformasi data, menunjukkan bahwa dataset siap untuk analisis lebih lanjut.

D. Data Mining

Proses data mining dilakukan dengan memanfaatkan data operator utama di *RapidMiner*, yaitu FP-Growth dan *Create Association Rule*. Dalam proses ini, kegunaan nilai minimum support, minimum confidence, Premises, Conclusion, LaPlace, Gain, p-s, lift dan *minimum Conviction* untuk menentukan aturan asosiasi yang relevan dalam dataset.



Gambar 11. Model Data Mining

1. Penerapan FP-Growth

Algoritma FP-Growth diimplementasikan dengan bantuan perangkat lunak *RapidMiner*, dan hasil dari implementasi ini terlihat pada Gambar 12. Dalam implementasi ini, FP-Growth digunakan untuk mengidentifikasi pola asosiasi yang sering terjadi dalam dataset, yang selanjutnya bisa digunakan untuk analisis tambahan dalam konteks pengambilan keputusan bisnis atau strategi pemasaran.



Gambar 12. Algoritma Fp-Growth

Hasil penerapan algoritma FP-Growth menunjukkan terbentuknya tiga itemset yang saling terkait, yang menggambarkan hubungan antar pola pembelian antar item dalam data set. Pola-pola ini

menceritakan ketertarikan produk berdasarkan transaksi yang telah dianalisis. Informasi rinci mengenai itemset tersebut, termasuk nilai *support* dan *confidence*, dapat dilihat pada Gambar 13 yang terlampir di bawah ini.

| Size | Support | Item 1 | Item 2 | Item 3 |
|------|---------|---------------|--------|--------|
| 1 | 0.915 | Aoka | | |
| 1 | 0.856 | Beras | | |
| 1 | 0.556 | Lampu | | |
| 1 | 0.547 | Coca Cola | | |
| 1 | 0.547 | Spiritus | | |
| 1 | 0.513 | Punama Toys | | |
| 1 | 0.504 | kenapuk | | |
| 1 | 0.496 | Mantel | | |
| 1 | 0.496 | Sari Roti | | |
| 1 | 0.496 | Ubi | | |
| 1 | 0.487 | Kunor Rambut | | |
| 1 | 0.479 | Peniti | | |
| 1 | 0.479 | Pisipi Parcel | | |
| 1 | 0.479 | Walidu | | |
| 1 | 0.479 | The Tank | | |
| 1 | 0.462 | Gula | | |
| 1 | 0.462 | Mangam | | |

Gambar 13. Hasil Fp-Growth

2. Create Association rule

Dalam penerapan algoritma FP-Growth dan analisis aturan asosiasi, peneliti berfokus pada pencarian nilai *confidence* yang optimal dengan mengatur parameter *minimum support* pada 0,95 dan *minimum confidence* pada 0,8. Pemilihan nilai *minimum support* sebesar 0,95 bertujuan untuk memastikan bahwa hanya itemset yang muncul dengan frekuensi tinggi dalam transaksi yang akan diperhitungkan. Strategi ini membantu menjamin relevansi pola asosiasi yang ditemukan, serta memastikan bahwa item tersebut memiliki cukup banyak kemunculan untuk dijadikan acuan dalam pengambilan keputusan bisnis. Sementara itu, nilai *minimum confidence* yang ditetapkan sebesar 0,8 diharapkan dapat memastikan bahwa hubungan antara produk yang teridentifikasi adalah signifikan. Dengan nilai *confidence* yang tinggi, peneliti dapat berasumsi bahwa jika suatu produk dibeli, kemungkinan besar produk lain juga akan ikut dibeli. Hal ini membuka peluang bagi perancangan strategi pemasaran atau bundling produk yang lebih efektif. Dari penerapan ini, diperoleh berbagai aturan asosiasi yang dapat dilihat pada gambar yang dilampirkan.



Gambar 14. Create Association Rules

| No. | Premises | Conclusion | Support | Confidence | Lift/Race | Gain | p-s | Lift |
|-----|--------------|-----------------|---------|------------|-----------|--------|--------|------|
| 9 | Peniti | Aoka | 0.393 | 0.821 | 0.942 | -0.564 | -0.045 | 0.1 |
| 10 | Peniti | Beras | 0.393 | 0.821 | 0.942 | -0.564 | 0.127 | 1.1 |
| 11 | Kunor Rambut | Aoka | 0.410 | 0.825 | 0.943 | -0.573 | -0.044 | 0.1 |
| 12 | Mantel | Spiritus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.1 |
| 13 | Sari Roti | Spiritus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.1 |
| 14 | Ubi | Spiritus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.1 |
| 15 | Mantel | Sari Roti | 0.410 | 0.828 | 0.943 | -0.581 | 0.165 | 1.1 |
| 16 | Sari Roti | Mantel | 0.410 | 0.828 | 0.943 | -0.581 | 0.165 | 1.1 |
| 17 | Mantel | Aoka, Spiritus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.1 |
| 18 | Sari Roti | Aoka, Spiritus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.1 |
| 19 | Ubi | Aoka, Spiritus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.1 |
| 20 | Aoka, Ubi | Spiritus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.1 |
| 21 | Mantel | Aoka, Sari Roti | 0.410 | 0.828 | 0.943 | -0.581 | 0.185 | 1.1 |
| 22 | Sari Roti | Aoka, Mantel | 0.410 | 0.828 | 0.943 | -0.581 | 0.185 | 1.1 |
| 23 | kenapuk | Aoka | 0.419 | 0.831 | 0.943 | -0.590 | -0.042 | 0.1 |
| 24 | Gula | Permen Kaki | 0.385 | 0.833 | 0.947 | -0.538 | 0.191 | 1.1 |
| 25 | Madu Rasa | Lampu | 0.376 | 0.893 | 0.958 | -0.496 | 0.134 | 1.1 |

Gambar 15. Hasil Association Rules

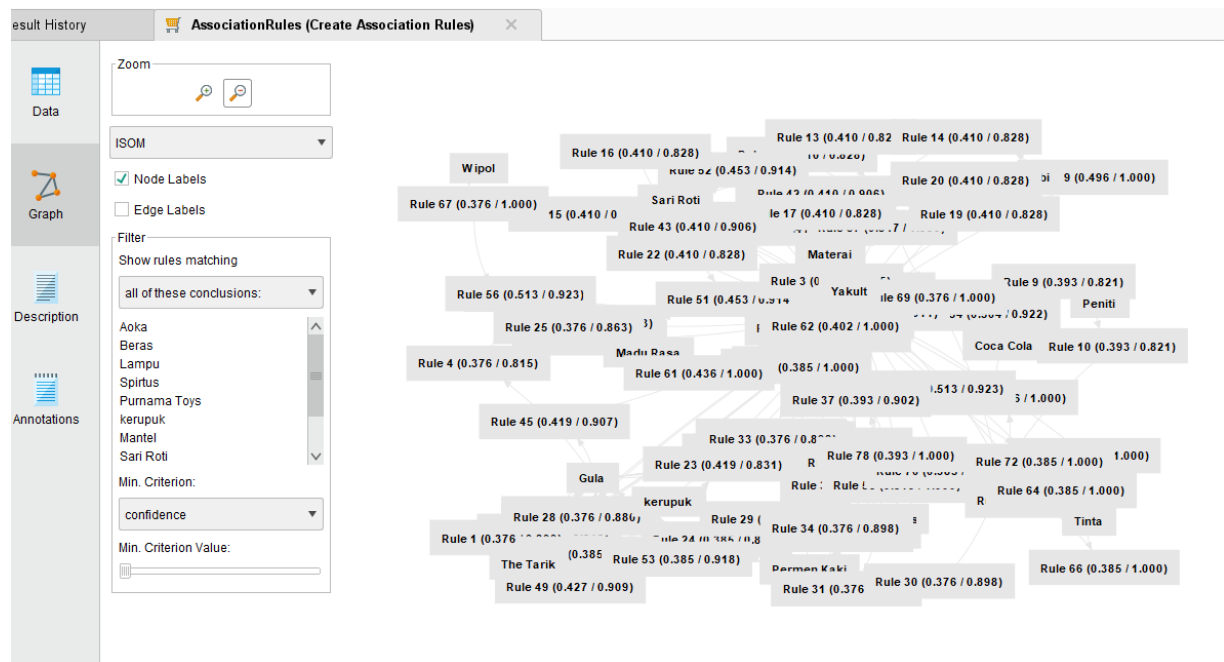
Hasil penerapan algoritma FP-Growth pada data aturan asosiasi menunjukkan adanya hubungan antara berbagai item dalam transaksi. Di dalam tabel yang tersedia, kolom *Premises* dan *Conclusion* menggambarkan aturan asosiasi yang teridentifikasi, di mana *Premises* adalah item yang menyebabkan pembelian item lain yang tertera dalam *Conclusion*. Sebagai contoh, aturan "Peniti, Aoka" memiliki *support* 0.393, yang berarti aturan ini muncul dalam 39.3% transaksi, dengan *confidence* 0.821, yang menunjukkan bahwa 82.1% transaksi yang mencakup peniti juga membeli Aoka. Nilai *Lift* yang tercatat adalah 0.965, yang menandakan adanya hubungan moderat antara peniti dan Aoka. Untuk aturan lainnya, seperti "Mantel, Aoka, Spiritus", ditemukan *support* 0.410 dan *confidence* 0.828, dengan nilai *Lift* 1.139, yang menunjukkan keterkaitan yang lebih kuat antara Mantel dan kombinasi Aoka serta Spiritus. Selain *support* dan *confidence*, tabel ini juga mencakup ukuran tambahan seperti *LaPlace*, *Gain*, *p-s*, dan *Lift* yang membantu menilai kekuatan dan relevansi dari aturan asosiasi yang ditemukan. Temuan ini memberikan wawasan penting yang dapat dimanfaatkan untuk merancang strategi pemasaran yang lebih efektif, seperti penggabungan produk atau promosi yang sesuai berdasarkan pola pembelian yang terlihat dalam dataset.

E. Evaluation

Evaluasi terhadap pola asosiasi yang ditemukan melalui algoritma FP-Growth melibatkan sejumlah metrik penting untuk menilai kekuatan dan keandalan dari aturan asosiasi yang dihasilkan. Salah satunya adalah *support*, yang mengukur frekuensi kemunculan kombinasi antara *Premises* dan *Conclusion* di seluruh dataset. Semakin tinggi nilai *support*, semakin sering kombinasi itemset tersebut muncul dalam transaksi. Sebagai contoh, pada baris pertama, kombinasi "The Tarik" dan "Gula" memiliki nilai *support* sebesar 0.376, yang berarti 37.6% dari seluruh transaksi melibatkan kedua item ini. Selanjutnya, ada metrik *confidence*, yang mengukur kekuatan hubungan antara *Premises* dan *Conclusion*. Nilai *confidence* yang lebih tinggi menunjukkan kemungkinan besar bahwa jika *Premises* dibeli, *Conclusion* juga akan ikut dibeli. Misalnya, pada baris pertama, *confidence* sebesar 0.800 menunjukkan bahwa 80% transaksi yang mencakup "The Tarik" juga melibatkan "Gula", mengindikasikan adanya hubungan yang cukup kuat. Metrik lain yang penting adalah *LaPlace*, yang memberikan koreksi pada perhitungan *confidence* dengan mempertimbangkan probabilitas kejadian secara acak. Hal ini memungkinkan Najah Mart untuk menilai ketepatan aturan asosiasi dengan lebih baik. Nilai *LaPlace* yang lebih tinggi menunjukkan prediksi yang lebih akurat. Pada baris pertama, nilai *LaPlace* sebesar 0.936 menunjukkan bahwa aturan asosiasi antara "The Tarik" dan "Gula" memiliki ketepatan yang tinggi. Selain itu, ada *Gain* yang mengukur keuntungan informasi dari aturan asosiasi. Nilai *gain* yang lebih tinggi menunjukkan bahwa aturan tersebut memberikan lebih banyak wawasan. Untuk aturan di baris pertama, nilai *gain* tercatat -0.564, yang mengindikasikan bahwa aturan ini menawarkan sedikit keuntungan dalam mengurangi ketidakpastian. *P-s* (*P-value Support*) juga menjadi pertimbangan, mengindikasikan seberapa besar pengaruh aturan tersebut terhadap prediksi hasil transaksi, dengan nilai yang lebih tinggi mencerminkan pengaruh yang lebih signifikan. *Lift* adalah metrik yang mengukur seberapa kuat hubungan antara *Premises* dan *Conclusion* dibandingkan dengan kemungkinan mereka muncul secara acak. Jika nilai *lift* lebih besar dari 1, ini menunjukkan adanya hubungan positif yang kuat antara dua item. Dalam kasus baris pertama, nilai *lift* yang mencapai 1.733 menunjukkan bahwa kombinasi "The Tarik" dan "Gula" memiliki hubungan yang lebih kuat dibandingkan jika keduanya muncul secara acak. Terakhir, *conviction* mengukur keandalan aturan asosiasi; nilai yang lebih tinggi menunjukkan aturan yang lebih dapat dipercaya dalam memprediksi hasil transaksi. Pada baris pertama, nilai *conviction* mencapai 2.692, yang menunjukkan bahwa aturan ini cukup terpercaya untuk memprediksi bahwa jika "The Tarik" dibeli, maka kemungkinan besar "Gula" juga akan dibeli. Kombinasi dari semua metrik ini memberikan gambaran yang komprehensif tentang keandalan dan kekuatan hubungan antar item dalam data penjualan, yang sangat bermanfaat untuk merancang strategi pemasaran dan pengelolaan stok produk.

Tabel 5. Hasil Evaluasi

| No | Premises | Conclusion | Support | Confidence | LaPlace | Gain | p-s | Lift | Conviction |
|----|---------------|-----------------|---------|------------|---------|--------|--------|-------|------------|
| 1 | The Tarik | Gula | 0.376 | 0.800 | 0.936 | -0.564 | 0.159 | 1.733 | 2.692 |
| 2 | The Tarik | Aoka, Gula | 0.376 | 0.800 | 0.936 | -0.564 | 0.179 | 1.910 | 2.906 |
| 3 | Materai | Aoka | 0.376 | 0.815 | 0.942 | -0.547 | -0.046 | 0.891 | 0.462 |
| 4 | Gula | Lampu | 0.376 | 0.815 | 0.942 | -0.547 | 0.120 | 1.467 | 2.400 |
| 5 | Gula | The Tarik | 0.376 | 0.815 | 0.942 | -0.547 | 0.159 | 1.733 | 2.862 |
| 6 | Gula | Aoka, Beras | 0.376 | 0.815 | 0.942 | -0.547 | 0.139 | 1.589 | 2.631 |
| 7 | Gula | Aoka, The Tarik | 0.376 | 0.815 | 0.942 | -0.547 | 0.179 | 1.907 | 3.092 |
| 8 | The Tarik | Kerupuk | 0.385 | 0.818 | 0.942 | -0.556 | 0.148 | 1.622 | 2.726 |
| 9 | Peniti | Aoka | 0.393 | 0.821 | 0.942 | -0.564 | -0.045 | 0.898 | 0.479 |
| 10 | Peniti | Beras | 0.393 | 0.821 | 0.942 | -0.564 | 0.127 | 1.479 | 2.489 |
| 11 | Kuncir Rambut | Aoka | 0.402 | 0.825 | 0.943 | -0.573 | -0.044 | 0.902 | 0.487 |
| 12 | Mantel | Spirtus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.513 | 2.627 |
| 13 | Sari Roti | Spirtus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.513 | 2.627 |
| 14 | Ubi | Spirtus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.513 | 2.627 |
| 15 | Mantel | Sari Roti | 0.410 | 0.828 | 0.943 | -0.581 | 0.165 | 1.669 | 2.925 |
| 16 | Sari Roti | Mantel | 0.410 | 0.828 | 0.943 | -0.581 | 0.165 | 1.669 | 2.925 |
| 17 | Mantel | Aoka, Spirtus | 0.410 | 0.828 | 0.943 | -0.581 | 0.139 | 1.513 | 2.627 |



Gambar 16. Hasil Graph

4. KESIMPULAN

Penelitian ini berhasil menerapkan algoritma FP-Growth untuk menganalisis pola asosiasi dalam transaksi penjualan. Dengan pengaturan parameter *minimum support* sebesar 0,95 dan *minimum confidence* sebesar 0,8, penelitian ini menghasilkan aturan asosiasi yang signifikan dan relevan bagi pengambilan keputusan bisnis. Berbagai metrik evaluasi, seperti *support*, *confidence*, *lift*, *LaPlace*, *Gain*, *P-s*, dan *conviction*, digunakan untuk menilai kekuatan serta keandalan aturan asosiasi yang dihasilkan. Hasil penelitian menunjukkan adanya hubungan yang kuat antara beberapa produk, seperti pada aturan "Peniti, Aoka" dengan support 0,393 dan confidence 0,821. Selain itu, aturan "Mantel, Aoka, Spiritus" menunjukkan hubungan yang lebih kuat dengan lift 1,139. Namun, penting untuk dicatat bahwa pola asosiasi yang ditemukan belum diuji atau divalidasi menggunakan metode lain, seperti uji statistik atau evaluasi langsung dari pelanggan, sehingga hanya mengandalkan FP-Growth sebagai metode utama. Walaupun demikian, hasil ini memberikan kontribusi penting dalam bidang data mining dengan menunjukkan bagaimana algoritma FP-Growth dapat digunakan untuk mengidentifikasi pola pembelian yang relevan, yang sangat berguna dalam meningkatkan strategi pemasaran. Dalam konteks industri ritel, temuan ini dapat digunakan untuk merancang strategi pemasaran yang lebih efektif, seperti penggabungan produk atau bundling, serta membantu pengelolaan inventaris berdasarkan pola pembelian yang sering terjadi. Penelitian ini juga memberikan gambaran tentang penerapan FP-Growth dalam analisis data transaksi untuk mendukung keputusan bisnis yang berbasis data, yang dapat meningkatkan daya saing serta efisiensi operasional dalam industri ritel.

UCAPAN TERIMA KASIH

Penulis menyampaikan rasa terima kasih kepada semua pihak yang telah berkontribusi dalam penelitian ini. Terutama kepada Najah Mart yang telah memberikan akses data transaksi yang diperlukan untuk analisis. Penulis juga menghargai masukan yang sangat berharga dari kolega peneliti dan akademisi selama proses penelitian ini. Di samping itu, penulis sangat mengapresiasi dukungan dari keluarga dan teman-teman yang selalu memberi motivasi dan semangat. Diharapkan hasil penelitian ini dapat memberikan dampak positif bagi pengembangan ilmu pengetahuan dan praktik bisnis di sektor ritel.

REFERENSI

- Agung, A., Daniswara, A., Kadek, I., & Nuryana, D. (2023). Data Preprocessing Pola Pada Penilaian Mahasiswa Program Profesi Guru. *Journal of Informatics and Computer Science*, 05(01), 97–100.
- Alghifari, F., & Juardi, D. (2021). Penerapan Data Mining Pada Penjualan Makanan Dan Minuman Menggunakan Metode Algoritma Naïve Bayes. *Jurnal Ilmiah Informatika*, 9(02), 75–81. <https://doi.org/10.33884/jif.v9i02.3755>
- Carudin. (2021). Pemanfaatan Data Transaksi untuk Dasar membangun Strategi berdasarkan Karakteristik Pelanggan dengan Algoritma K-Means Clustering dan Model RFM. *Jurnal Teknologi Terpadu*, 7(1), 7–14. <https://doi.org/10.54914/jtt.v7i1.318>
- Erwansyah, K., Andika, B., & Gunawan, R. (2021). Implementasi Data Mining Menggunakan Asosiasi Dengan Algoritma Apriori Untuk Mendapatkan Pola Rekomendasi Belanja Produk Pada Toko Avis Mobile. *J-SISKO TECH (Jurnal Teknologi Sistem Informasi Dan Sistem Komputer TGD)*, 4(1), 148. <https://doi.org/10.53513/jsk.v4i1.2628>
- Erwin, E. (2019). Analisis Market Basket Dengan Algoritma Apriori Dan FP-Growth. *Jurnal Generic*, 4(2), 26–30.
- Harahap, S. Z., & Nastuti, A. (2019). Teknik Data Mining Untuk Penentuan Paket Hemat Sembako. *Jurnal Ilmiah Fakultas Sains Dan Teknologi*, 7(3), 111–119.
- Indah, I., & Ali, I. (2024). Penerapan Algoritma Fp Growth Untuk Mendukung Pola Pembelian Sembako Di Toko Uci. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 8(2), 1643–1650. <https://doi.org/10.36040/jati.v8i2.9004>
- Muhammad Alvin, Alwis Nazir, M Fikry, Jasril, & Fadhilah Syafria. (2022). Implementasi Algoritma Fp-Growth Untuk Mengetahui Faktor Yang Berpengaruh Terhadap Kemampuan Membaca Al-Quran Siswa. *Jurnal RESTIKOM: Riset Teknik Informatika Dan Komputer*, 2(2), 66–78. <https://doi.org/10.52005/restikom.v2i2.67>
- Munanda, E., & Monalisa, S. (2021). Penerapan Algoritma Fp-Growth Pada Data Transaksi Penjualan Untuk Penentuan Tataletak. *Jurnal Ilmiah Rekayasa Dan Manajemen Sistem Informasi*, 7(2), 173–184. <http://ejournal.uin-suska.ac.id/index.php/RMSI/article/view/13253>
- Nurasiah. (2021). Implementasi Algoritma FP-Growth Pada Pengenalan Pola Penjualan. *TIN: Terapan Informatika Nusantara*, 1(9), 438–444.
- Raffles, S. A. (2023). Peran Penting Pengolahan Data Dalam Transformasi Bisnis Melalui Analisis. *Jurnal Rimba : Riset Ilmu Manajemen Bisnis Dan Akuntansi*, 2(1), 321–340. <https://doi.org/10.61132/rimba.v2i1.572>
- Raihan, M. (2024). Analisis Perbandingan Algoritma Apriori dan FP-Growth untuk Menentukan Strategi Penjualan Pada Maestro Jakarta Cafe & Space Abstrak. *Jurnal Indonesia : Manajemen Informatika Dan Komunikasi*, 5(3), 3147–3157. <https://doi.org/https://doi.org/10.35870/jimik.v5i3.994>
- Sari, L., & Sari siregar, G. yanti kemala. (2021). Perancangan Aplikasi Pendataan Data Kepegawaian Negeri Sipil Pada Dinas Komunikasi Dan Informatika Kota Metro. *Jurnal Mahasiswa Ilmu Komputer*, 1(2), 115–135. <https://doi.org/10.24127/.v2i1.1235>
- Sumilat, M. F., Malonda, N. S. H., & Punuh, M. I. (2019). Hubungan Antara Status Imunisasi dan Pemberian ASI Eksklusif dengan Status Gizi Balita Usia 24-59 bulan di Desa Tateli Tiga Kecamatan Mandolang Kabupaten Minahasa. *Jurnal KESMAS*, 8(6), 326–334.
- Tarwoto, AL-Haq, A. V., Fidela, A., Audiana, W., & Zulfa Ummu Hani. (2025). Penerapan Algoritma FP-Growth untuk Strategi Penjualan Toko Kelontong Cipta Lestari. 9(2), 444–451.

- Valencia, S., & Atmojo, W. T. (2024). *Analisis Pola Pembelian pada Data Penjualan CanNgopi menggunakan Algoritma FP-Growth*. 8(2), 214–224. <https://doi.org/https://doi.org/10.31603/komtika.v8i2.12672>
- Widayati, Q. (2018). PENERAPAN DATA MINING MENGGUNAKAN METODE TEKNIK CLASSIFICATION UNTUK MELIHAT POTENSI KEPATUHAN WAJIB PAJAK BUMI DAN BANGUNAN. *Jurnal Ilmiah MATRIK*, Vol.20 No., 163–174. <https://download.garuda.kemdikbud.go.id/article.php?article=1038644&val=11485&title=PENERAPAN+DATA+MINING+MENGGUNAKAN+METODE+TEKNIK+CLASSIFICATION+UNTUK+MELIHAT+POTENSI+KEPATUHAN+WAJIB+PAJAK+BUMI+DAN+BANGUNAN>